实验二：白葡萄酒质量回归（实验报告）

学院：计算机科学与网络空间安全学院　姓名：李梦涛　学号：2412483

一、实验概述

题目：白葡萄酒质量回归

实验要求：

级别	要求
初级	4:1 划分训练/测试集并做预处理；手写线性回归，分别用 BGD 与 SGD 优化；输出训练/测试 MSE 并绘制收敛曲线；对比不同学习率并选择较优值
中级	比较 BGD 与 SGD 的误差、收敛速度与稳定性；分析至少 3 个特征对质量预测的影响；用训练集 Pearson 系数选出最相关的一对特征，做“保留 / 去掉其一”的系数与 MSE 对照实验
高级	手写岭回归（L2 正则化），报告平均训练误差与平均测试误差，并注明偏置项约定

开发环境：Python 3.14.0、NumPy 2.4.1、pandas 3.0.0、scikit-learn 1.9.1（仅用于数据划分、标准化、评估指标与对比验证）、Matplotlib 3.10.8；

代码仓库：KaGaMi9999/nku-2026-machinelearning

二、数据集预处理及划分

2.1 数据概况

数据文件为 `winequality-white.csv`，字段以分号 `;` 分隔。读取结果：**4898 行 × 12 列**，前 11 列为理化指标，最后一列 `quality` 为质量评分（3~9 的整数）。**无缺失值**，不做去重。

quality 分布高度不平衡：

评分	3	4	5	6	7	8	9
样本数	20	163	1457	2198	880	175	5

评分均值 5.878、标准差 0.886，绝大多数样本集中在 5~7 分，3 分与 9 分极少，这直接限制了回归模型可达到的精度。

各特征量纲差异显著（`density` 标准差仅 0.003，`total sulfur dioxide` 标准差达 42.5），且 `residual sugar`、`chlorides` 等呈明显右偏（偏度分别为 1.08、5.02）：

特征	均值	标准差	最小值	最大值
fixed acidity	6.8548	0.8438	3.80	14.20
volatile acidity	0.2782	0.1008	0.08	1.10
citric acid	0.3342	0.1210	0.00	1.66
residual sugar	6.3914	5.0715	0.60	65.80
chlorides	0.0458	0.0218	0.009	0.346
free sulfur dioxide	35.3081	17.0054	2.00	289.00
total sulfur dioxide	138.3607	42.4937	9.00	440.00
density	0.9940	0.0030	0.9871	1.0390
pH	3.1883	0.1510	2.72	3.82
sulphates	0.4898	0.1141	0.22	1.08
alcohol	10.5143	1.2305	8.00	14.20

2.2 预处理

1. **读取**：`pd.read_csv(..., sep=";")`，全部 11 个特征均为数值型，无需编码。
2. **标准化（z-score）**：对每个特征 $x' = (x - \mu) / \sigma$，其中 **μ、σ 只由训练集计算**，再原样作用于测试集，避免信息泄漏。标准化是梯度下降能正常收敛的前提：若直接用原始尺度，`density` 方向的梯度比 `total sulfur dioxide` 小 4 个数量级，学习率要么在硫方向发散、要么在密度方向几乎不动。
3. **偏置项**：在标准化特征后拼接全 1 列，记特征维数 $n = 12$，模型写作 $h_\theta(x) = \theta^T[x; 1]$。

2.3 训练/测试划分

使用 `train_test_split(test_size=0.2, stratify=y, random_state=42)`，按 `quality` 分层抽样，得到 **训练集 3918 条、测试集 980 条**，两者评分分布基本一致：

评分	3	4	5	6	7	8	9
训练集	16	130	1166	1758	704	140	4
测试集	4	33	291	440	176	35	1

不分层时，9 分样本（共 5 条）有较大概率全部落入训练集，此时测试集将失去该评分档，因此进行分层抽样，分层抽样同时保证每个评分档在测试集中都有代表。

三、实现思路与关键代码

3.1 目标函数与梯度

采用均方误差作为目标函数（m 为样本数）：

```
J(θ) = (1/m) · Σ_i (h_θ(x_i) − y_i)²
∇J(θ) = (2/m) · Xᵀ(Xθ − y)
```

BGD 每轮使用全部训练样本计算梯度；SGD 每轮先随机打乱样本，再对每个样本用其单样本梯度 `2(h_θ(x_i) − y_i)·x_i` 更新一次参数。一次完整遍历称为一个 epoch。BGD 与 SGD 的初始参数均取 `θ = 0`。

3.2 关键代码

BGD 核心（`codes/linreg_bgd_sgd.py`）：

```python
for epoch in range(epochs):
    grad = (2.0 / m) * (Xb.T @ (Xb @ theta - y))
    theta = theta - lr * grad
    train_hist[epoch] = mse(Xb, y, theta)
    test_hist[epoch] = mse(Xb_te, y_te, theta)
```

SGD 核心：

```
for epoch in range(epochs):
    for i in rng.permutation(m):
        xi = Xb[i]
        err = xi @ theta - y[i]
        theta = theta - lr * 2.0 * err * xi
    train_hist[epoch] = mse(Xb, y, theta)   # 每个 epoch 末在全集上评估
```

岭回归解析解（`codes/ridge.py`，偏置项不惩罚）：

```
xm, ym = X.mean(axis=0), y.mean()
Xc, yc = X - xm, y - ym
w = np.linalg.solve(Xc.T @ Xc + lam * np.eye(X.shape[1]), Xc.T @ yc)
b = ym - xm @ w          # 等价于对 [X,1] 加惩罚掩码 [1,...,1,0]
```

偏置项约定：只惩罚 11 个特征的系数，偏置项 b 不参与惩罚。~~~~

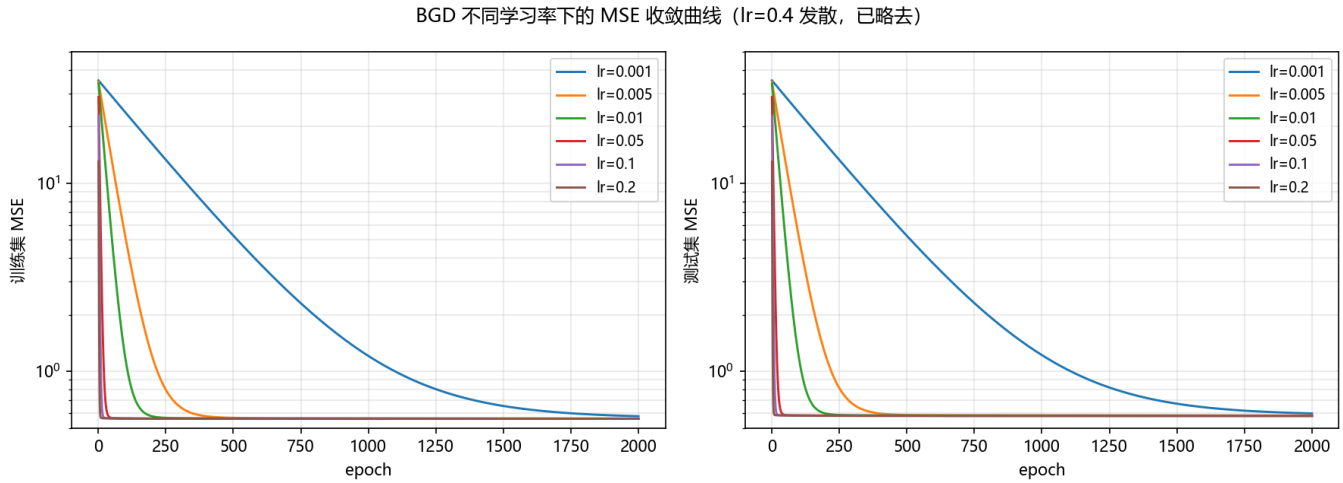
3.3 超参数设置

项目	设置
BGD 学习率	0.001、0.005、0.01、0.05、0.1、0.2、0.4
BGD epoch	2000
SGD 学习率	1e-4、5e-4、1e-3、5e-3、1e-2、2e-2
SGD epoch	40（每个学习率取 3 个随机种子的平均，曲线做 5 点滑动平均）
岭回归 λ	1e-4 ~ 1e3 共 22 个对数等距取值，训练集内 5 折交叉验证选择
评价指标	MSE、R^2

四、实验结果与分析

4.1 BGD：学习率的影响

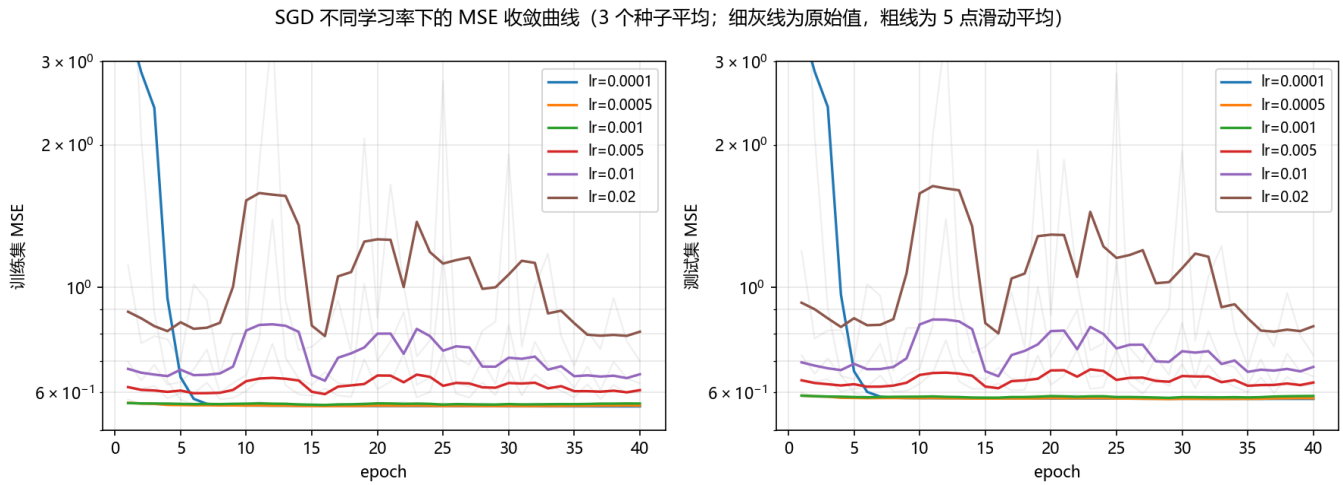
学习率	训练 MSE	测试 MSE	表现
0.001	0.577219	0.597243	2000 epoch 内未收敛
0.005	0.561368	0.582272	接近最优
0.01	0.560246	0.580975	接近最优
0.05	0.559460	0.579419	收敛
0.1	0.559460	0.579388	收敛
0.2	0.559460	0.579387	收敛（最快）
0.4	NaN	NaN	发散



分析：目标函数是二次型，Hessian 为 $(2/m)X^TX$，其最大特征值 $L \approx 6.46$，理论上学习率需满足 $lr < 2/L \approx 0.31$ 才不发散，$lr < 1/L \approx 0.155$ 时参数在各方向上都不会过冲。实验结果与之吻合：0.2 仍能收敛（损失单调下降，但参数在陡峭方向上会来回摆动），0.4 直接发散（第 1 个 epoch 后 MSE 溢出）；学习率越小收敛越慢，0.001 在 2000 轮后仍未到达最优点。综合收敛速度与稳定性，**BGD 选择 lr = 0.2**（0.05~0.2 的最终 MSE 基本相同，说明均已充分收敛）。

4.2 SGD：学习率的影响

学习率	训练 MSE	测试 MSE（3 种子）
1e-4	0.560696	0.581577 ± 0.0001
5e-4	0.562448	0.583584 ± 0.0011
1e-3	0.568547	0.590618 ± 0.0043
5e-3	0.600217	0.623247 ± 0.0182
1e-2	0.627098	0.649043 ± 0.0212
2e-2	0.698541	0.719646 ± 0.0726

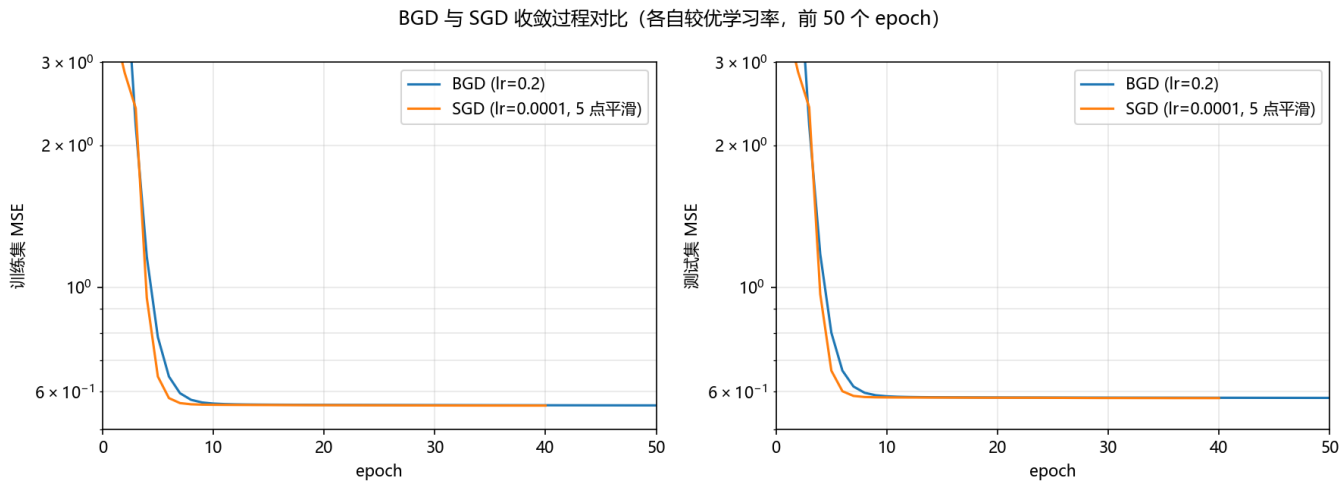


分析：SGD 的曲线呈现明显的锯齿波动——每次更新只用一个样本，梯度是真实梯度的无偏但高方差估计，参数在最优点附近持续抖动。学习率越大，抖动幅度与种子间方差越大：lr=2e-2 时测试 MSE 的种子标准差已达 0.073，而 lr=1e-4 仅 0.0001。因此 SGD 的"较优学习率"是**收敛速度与噪声水平之间的折中**：本实验中 1e-4 的最终误差最低，但收敛较慢；若要求更快收敛，5e-4~1e-3 更合适。

4.3 BGD 与 SGD 对比

模型	训练 MSE	测试 MSE	收敛所需 epoch
BGD（lr=0.2）	0.559460	**0.579387**	约 11
SGD（lr=1e-4）	0.560696	0.581577	约 7
正规方程闭式解	0.559460	0.579387	—

（收敛 epoch 的判定标准：训练 MSE 首次降到 0.565，即最优值 0.55946 的 1% 以内。）



分析：

- **误差**：两者最终测试 MSE 仅差 0.0022（0.38%），都收敛到线性模型的最优解附近，BGD 略优。SGD 的常数学习率使其无法精确停在最优点，存在约 0.001 的噪声底。
- **收敛速度**：按 epoch 计 SGD 更快，但一个 SGD epoch 包含 3918 次参数更新，计算代价远高于一次 BGD 更新；若按参数更新次数比较，BGD 反而更"省"。这体现了 SGD 的优势在于单步代价低、适合大规模数据，而非总更新次数少。
- **稳定性**：BGD 曲线单调平滑；SGD 曲线每轮都在波动，且对学习率、随机种子敏感（同学习率下种子间 MSE 标准差最大可达 0.07）。

4.4 实现正确性校验

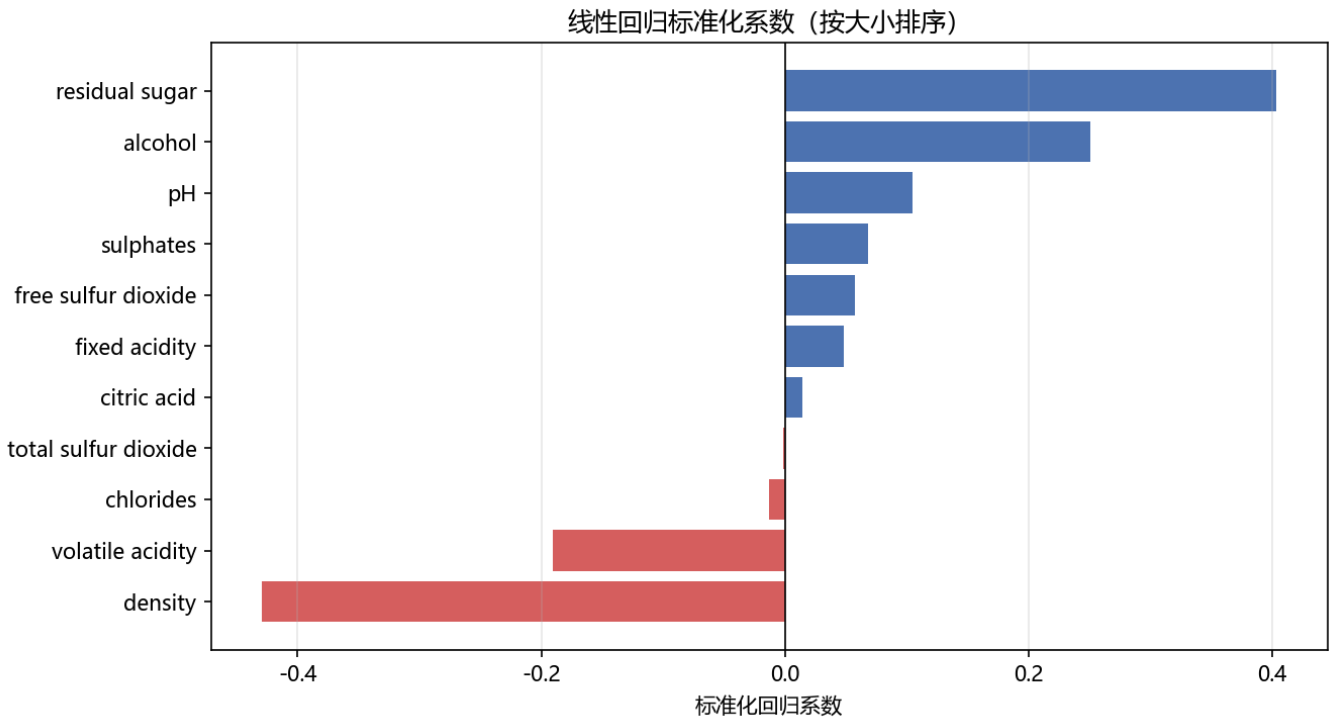
模型	训练 MSE	测试 MSE
手写正规方程闭式解	0.559460	0.579387
sklearn `LinearRegression`（仅对比）	0.559460	0.579387
手写 BGD（lr=0.2）	0.559460	0.579387

手写闭式解与 sklearn 的系数最大绝对差为 `4.8e-14`，手写 BGD 与正规方程的系数最大绝对差为 `6.4e-9`，说明手写的目标函数、梯度与更新公式均正确。测试集 R^2 = 0.2619，即 11 个理化指标只能解释约 26% 的质量评分方差，说明线性模型在该数据上的解释能力有限，这是因为评分是主观的，离散的且差异性较大的特性。

4.5 特征影响分析

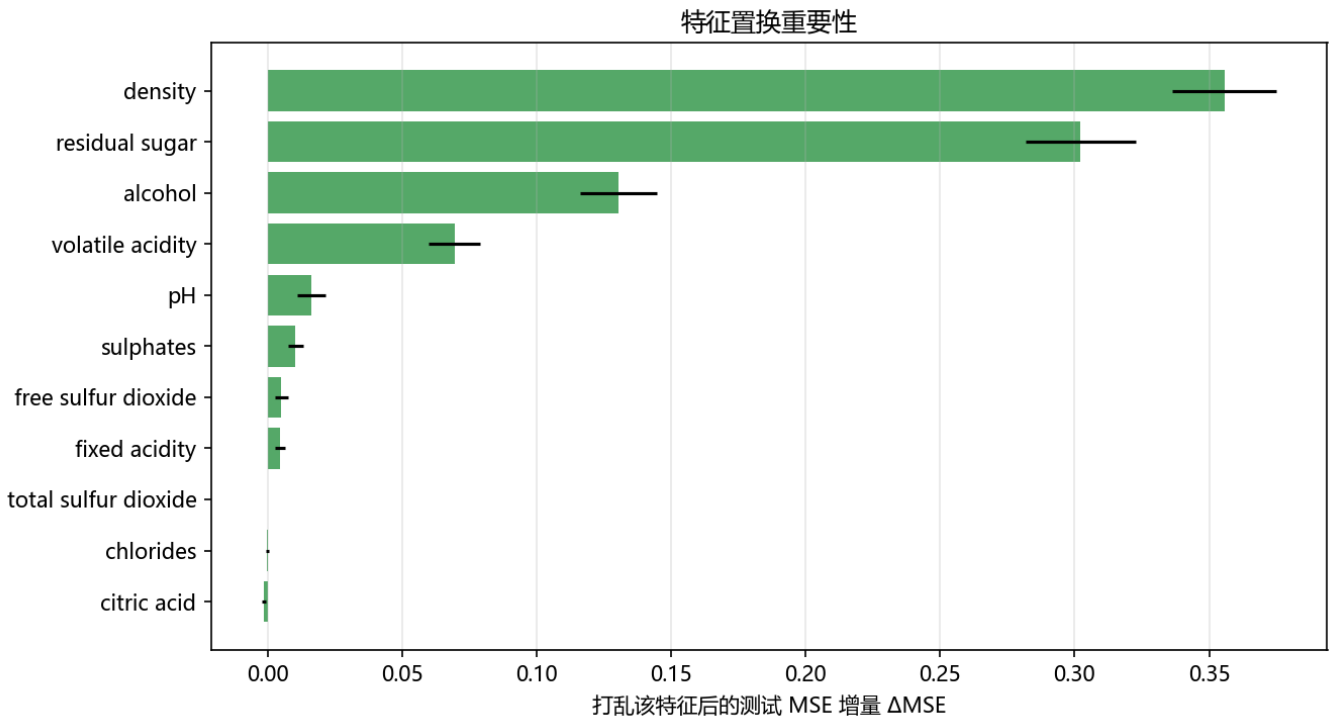
标准化后的回归系数（可直接比较相对影响大小）：

特征	系数	特征	系数
density	**−0.4291**	sulphates	0.0685
residual sugar	**0.4034**	free sulfur dioxide	0.0574
alcohol	**0.2508**	fixed acidity	0.0481
volatile acidity	**−0.1907**	citric acid	0.0142
pH	0.1047	chlorides	−0.0128
		total sulfur dioxide	−0.0015



考虑到特征之间存在相关性，系数大小可能被“分摊”，进一步做了**置换重要性**实验：在测试集上随机打乱某一特征 30 次，统计测试 MSE 的平均增量。

特征	ΔMSE 均值	标准差
density	0.3557	0.0193
residual sugar	0.3022	0.0205
alcohol	0.1305	0.0143
volatile acidity	0.0695	0.0096
pH	0.0161	0.0053
sulphates	0.0104	0.0029
free sulfur dioxide	0.0051	0.0024
fixed acidity	0.0046	0.0020
total sulfur dioxide	0.0001	0.0001
chlorides	−0.0002	0.0006
citric acid	−0.0014	0.0006



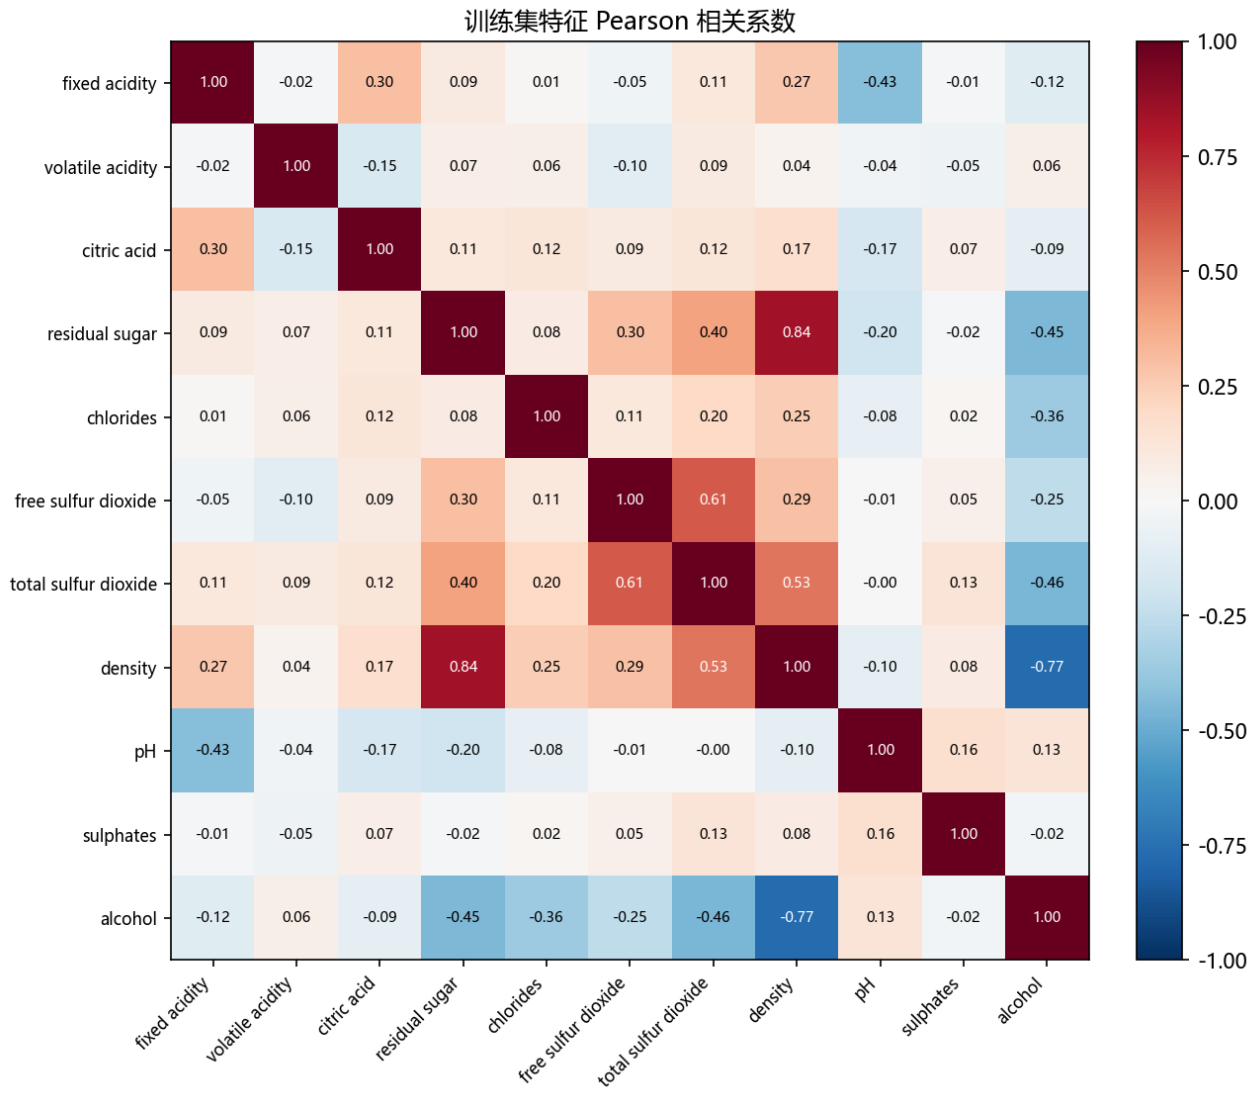
分析:

- **alcohol（酒精度，正相关）**：系数 +0.2508，置换后 MSE 增加 0.13。酒精是影响口感与评分的最主要正向因素之一，酒精度越高评分倾向越高。

- **volatile acidity（挥发性酸，负相关）**：系数 −0.1907，置换后 MSE 增加 0.069。挥发性酸过高会带来醋味，是典型的负面指标。
- **density（密度）与 residual sugar（残糖）**：两者系数绝对值最大且符号相反（−0.4291 与 +0.4034），置换重要性也最高。但它们高度相关（见 4.6），系数的"分摊"使单个系数不能单独解释为因果效应；从机理上，残糖高会提高密度，而密度高本身对应酒精/糖分的组合，因此两者的正负号需结合共线性理解。
- **chlorides、citric acid** 的置换重要性为负：打乱它们后测试 MSE 反而略降，说明在当前线性模型中这两个特征主要贡献噪声，可考虑剔除。

4.6 相关特征与共线性实验

训练集 Pearson 相关系数热力图：



相关性最强的一对特征是 **residual sugar 与 density，r = 0.8399**（其次是 free/total sulfur dioxide，r = 0.61；density 与 alcohol，r = −0.77）。对这对特征做对照实验：

模型	residual sugar 系数	density 系数	训练 MSE	测试 MSE
保留两者	0.4034	−0.4291	0.559460	0.579387
去掉 residual sugar	—	**+0.1301**	0.572983	0.592689
去掉 density	**0.1307**	—	0.566476	0.586910

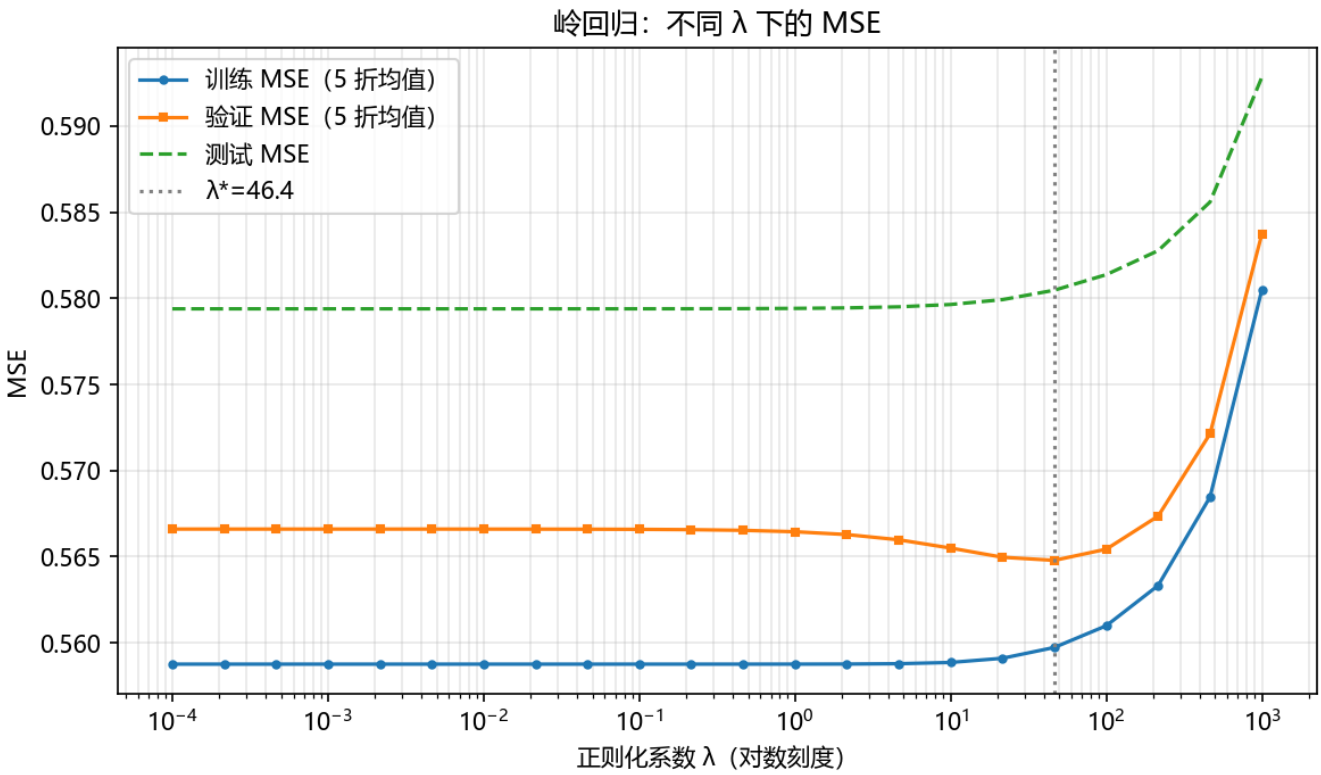
分析：

- **系数极不稳定**：两者同时保留时符号一正一负、量级相当；只保留 density 时其系数由 −0.43 变成 **+0.13（符号翻转）**；只保留 residual sugar 时其系数由 0.40 降到 0.13。这正是多重共线性的典型表现——两个高度相关的特征共同解释同一部分方差，模型无法唯一分配权重。
- **其他系数也被牵连**：去掉 density 后，alcohol 的系数从 0.2508 增大到 0.4467，fixed acidity 从 +0.0481 变为 −0.0456，pH 从 0.1047 降到 0.0283。共线性不只影响这对特征本身，其他系数也会被牵连。
- **预测效果影响较小**：三种模型的测试 MSE 分别为 0.5794、0.5927、0.5869，最多只差 2.3%。说明存在共线性时，**系数不可解释，但预测值仍相对稳定。**

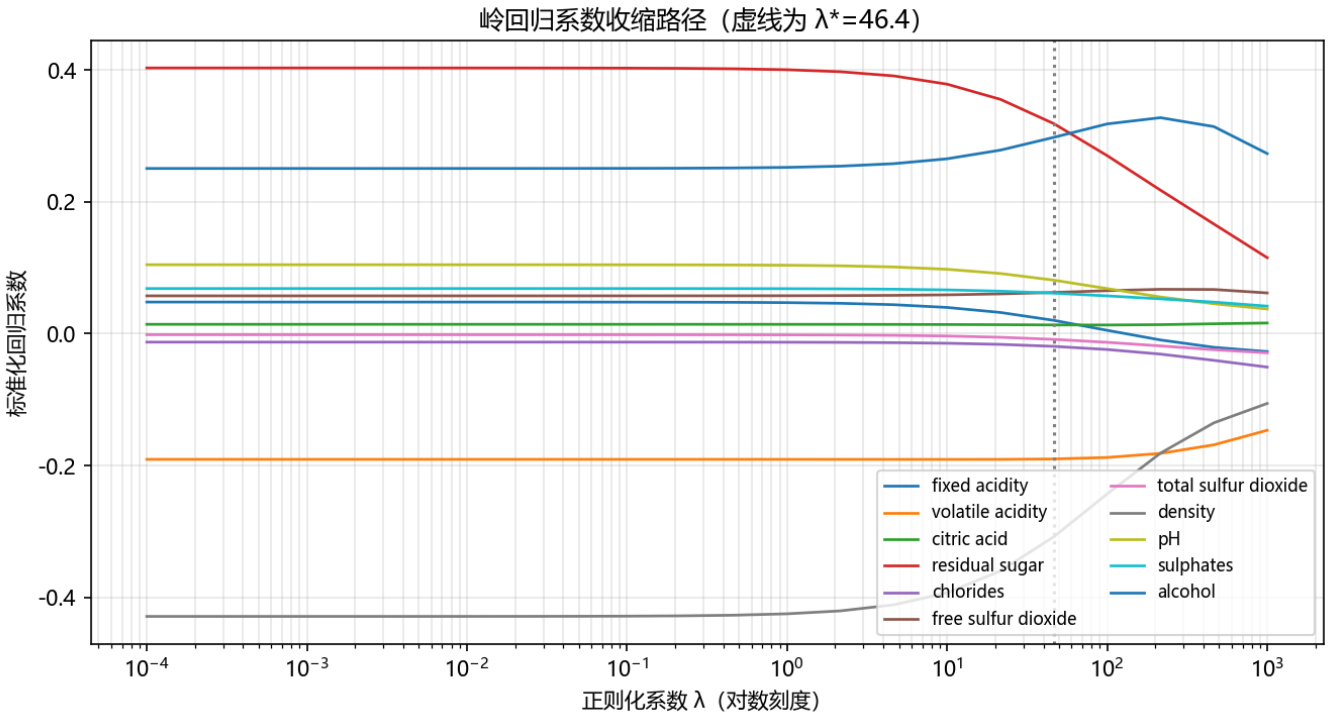
4.7 岭回归（L2 正则化，解析法）

在训练集内做 5 折交叉验证选择 λ（λ 从 1e-4 到 1e3 共 22 个对数等距取值）：

λ	平均训练 MSE	平均验证 MSE
1e-4	0.558761	0.566602
4.6e-3	0.558761	0.566601
0.464	0.558761	0.566528
21.54	0.559102	0.564966
46.42（λ*）	**0.559729**	**0.564786**
1000	0.580508	0.583748



- **最优 λ = 46.42**：此时 **平均训练MSE 0.559729、平均验证MSE 0.564786**（5 折验证 MSE 标准差 0.019406，主要来自各折样本量差异）。
- 在全部训练集上重训后：训练 MSE = 0.560084，**测试 MSE = 0.580468**；而 λ=0（普通最小二乘）为 0.559460 / 0.579387。岭回归的测试误差比 OLS 高约 0.0011（0.19%）。



系数变化（λ* 与 OLS 对比）：

特征	OLS (λ=0)	Ridge (λ*)	特征	OLS (λ=0)	Ridge (λ*)
density	−0.4291	−0.3082	sulphates	0.0685	0.0615
residual sugar	0.4034	0.3188	free sulfur dioxide	0.0574	0.0626
alcohol	0.2508	0.2980	fixed acidity	0.0481	0.0202
volatile acidity	−0.1907	−0.1902	citric acid	0.0142	0.0133
pH	0.1047	0.0813	chlorides	−0.0128	−0.0192
			total sulfur dioxide	−0.0015	−0.0086

系数向量的 L2 范数从 **0.6839 降到 0.5805（−15%）**，其中共线性最强的 density 与 residual sugar 收缩幅度最大（分别约 28% 与 21%），而 alcohol 的系数反而略有上升（0.2508 → 0.2980）；偏置项在两模型中均为 5.8780（不参与惩罚）。

分析：本数据中 λ 从 1e-4 到约 10 的区间内验证误差几乎不变（曲线极平），说明特征矩阵虽然条件数不大（约 146），但共线性使某些方向上的估计方差偏高；岭回归通过收缩降低了方差，但由于该数据噪声占主导、真实信号较弱，偏差的增加抵消了方差的收益，因此测试误差没有改善，λ 增大到 100 以上后误差迅速上升（欠拟合）。在本实验中岭回归的主要作用是**稳定系数**，对提高预测精度作用有限。

五、总结

1. **初级**： BGD/SGD 线性回归，测试集 MSE 分别为 0.5794 与 0.5816；BGD 在 lr=0.2 时约 11 个 epoch 将训练 MSE 降到最优值的 1% 以内，lr=0.4 发散（与理论上界 2/L≈0.31 吻合）；SGD 在 lr=1e-4 时噪声最小。
2. **中级**：BGD 平滑但单步代价高，SGD 收敛快但方差大；影响最大的特征是 density、residual sugar、alcohol 与 volatile acidity；residual sugar 与 density 的相关系数达 0.84，去掉任一个都会导致系数符号/量级剧变，而测试 MSE 仅变化 1%~2.3%，是典型的多重共线性。
3. **高级**：解析法岭回归（偏置不惩罚）5 折交叉验证选出 λ*=46.42，平均训练误差 0.559729、平均验证误差 0.564786，测试 MSE 0.580468；系数范数缩小 15%，但没有带来预测精度提升，说明本数据中正则化的作用是稳定系数而对提高精度作用有限。

局限与改进：质量评分是有序离散值且分布极不平衡，线性回归 + MSE 难以刻画；后续可尝试特征变换（对数/多项式）、有序回归或树模型；SGD 可加入学习率衰减以降低噪声底。

附录：文件结构

```
Lab2/
├── codes/
│   ├── linreg_bgd_sgd.py      # 初级+中级：BGD/SGD、学习率对比、闭式解校验
│   ├── feature_analysis.py    # 中级：系数、置换重要性、相关性、共线性实验
│   ├── ridge.py               # 高级：解析法岭回归 + 5 折 CV 选 λ
│   └── requirements.txt       # 依赖清单
├── reports/
│   ├── lab2_report.md         # 本报告
│   ├── lab2_report.pdf        # PDF 版
│   ├── linreg_outputs.txt     # BGD/SGD 运行日志
│   ├── feature_outputs.txt    # 特征分析运行日志
│   ├── ridge_outputs.txt      # 岭回归运行日志
│   └── figs/                  # 全部实验图
└── winequality-white.csv      # 原始数据
```

复现方式：`cd Lab2 && python codes/linreg_bgd_sgd.py && python codes/feature_analysis.py && python codes/ridge.py`